

Uygulamalı Yapay Zeka Dersi

Dönem Projesi

Proje Başlığı: Hava Savunma Gözetimi İçin Derin Öğrenme ile İHA-Kuş Ayrımı: Yanlış Alarm ve Veri Setleri Arası Genelleme Analizi

Proje Türü / Üyeler: Bireysel Proje / Sena Nur Sünbül

1. Seçilen Problemin Tanımı

Küçük insansız hava araçları (İHA), hava sahası savunması ve sınır güvenliği gibi alanlarda ciddi güvenlik riskleri oluşturmaktadır. Görüntü tabanlı algılama sistemlerinin temel sorunlarından biri, özellikle uzak mesafedeki kuşların İHA sanılarak yanlış alarm (false-positive) sebep olmasıdır [6]. Bu projede problem, görüntüdeki nesnenin "İHA" veya "Kuş" olarak ayırt edildiği bir ikili görüntü sınıflandırması olarak ele alınmıştır (İHA pozitif sınıf). Çalışmanın sınırları ve metodolojisi şu şekilde planlanmıştır:

Veri Ön İşleme (Odaklı Kırpma): Uygulama senaryosu hava savunma ve sınır güvenliği gözetimi olduğundan, nesne tespiti (YOLO/Roboflow) formatındaki veri setlerinde bulunan koordinatlar (bounding box) kullanılarak görüntüler algoritmik olarak kırılacak ve sınıflandırma modellerine doğrudan hedefin kendisi verilecektir.

Arka Plan Gürültüsü Filtreleme: Modelin nesnenin duruşunu veya arka planı ezberlemesini önlemek için, yerde ya da dalda duran yakın çekim kuş görüntüleri filtrelenerek sadece havada uçan (in-flight) ve gökyüzü arka planında görünen nesnelere odaklanılacaktır. Ek olarak, yinelenen görüntüler algısal özet (perceptual hash) yöntemiyle tespit edilip eğitim ve test kümeleri arasından temizlenecektir.

Araştırma Soruları: Çalışma temel olarak üç soruyu hedeflemektedir:

1. İHA-kuş ayrımında en dengeli sonucu hangi mimari verir?
2. Bir veri setinde eğitilen model diğerlerinde nasıl genelleşir? (Her seferinde bir veri seti dışarıda bırakılarak çapraz doğrulama yapılacaktır).
3. Hatalı alarmlar (Kuşun İHA sanıldığı durumlar) spesifik olarak hangi görsel koşullarda yoğunlaşmaktadır?

Modeller ve Metrikler: Temel çizgi (baseline) olarak HOG+SVM kullanılacak; derin öğrenme tarafında ise sıfırdan eğitilmiş CNN, ResNet-50, EfficientNet-B0 ve MobileNetV3 mimarileri kıyaslanacaktır. Modeller; doğruluk, kesinlik, duyarlılık, F1, ROC-AUC ve yanlış alarm oranı ölçütleriyle değerlendirilecek, hatalar Grad-CAM ile görselleştirilecektir. Veri setleri genel amaçlı açık görüntülerden oluştuğundan sonuçlar gerçek bir savunma sensörü verisine doğrudan aktarılamaz; bu durum sınırlılık olarak raporlanacaktır.

2. Veri Setleri

1. Drone vs Bird: Aerial Object Classification Dataset (Kaggle, kullanıcı: muhammadsaoodsarwar; "drones" ve "birds" klasörleri). Bağlantı: <https://www.kaggle.com/datasets/muhammadsaoodsarwar/drone-vs-bird>

2. Drone vs bird v3: (Roboflow Universe, çalışma alanı: drone-vs-bird-4idpt; sürüm 3; proje sayfasında 2528 görüntü). Bağlantı: <https://universe.roboflow.com/drone-vs-bird-4idpt/drone-vs-bird-v3/dataset/3>

3. Drone-vs-Bird: (Kaggle, kullanıcı: romsham; adına göre YOLO formatı için hazırlanmış). Bağlantı: <https://www.kaggle.com/datasets/romsham/dronevsbird-foryolo>

Görüntü sayıları, sınıf dağılımı, boyut ve etiket biçimleri Faz 1'de çıkarılacaktır.

3. Literatür Taraması

Bu üç veri setini kullanan hakemli bir yayın taranan kaynaklarda bulunamamıştır; bu nedenle aynı problemi (İHA-kuş ayrımı) farklı veri setleriyle ele alan çalışmalar incelenmiştir. [6] Drone-vs-Bird yarışmasında kuşların yanlış alarmı yol açtığı ve uzak mesafenin en zor durum olduğu gösterilmiştir. [1] İHA ve kuşlardan oluşan YOLO etiketli bir veri seti sunmuş; [4] bu veriyle önceden eğitilmiş VGG16 ve enerji tabanlı modelleri kullanıp İHA'yı dağılım-ıçi, kuşu dağılım-dışı sayarak AUC 0,90 elde etmiş; [5] uzamsal-zamansal bir ağı YOLOv5, Faster R-CNN, SSD, RetinaNet ve R-FCN ile kıyaslayıp F1=0,974 bildirmiş, ancak bağımsız veride doğruluğun %91,3'e gerilediğini göstermiştir. [2] dört sınıflı AOD-4 veri setini sunmuş ve gündüz ağırlıklı görüntüleri ile sınıflar arası arka plan dengesizliğini sınırlılık olarak belirtmiş; [3] bu veride özel hafif CNN ile %97,12 doğruluk bildirmiştir. İncelenen çalışmalar çoğunlukla tek veri setinde yüksek başarı bildirmekte, genelleme en fazla tek bağımsız veriyle sınanmakta ve kuş-İHA yanlış alarm oranı ana ölçüt olarak öne çıkarılmamaktadır. Bu proje üç bağımsız veri seti ve "bir veri setini dışarıda bırak" yöntemiyle bu boşluğu hedefler.

Kaynakça

- [1] S. K. Shandilya, A. Srivastav, K. Yemets, A. Datta, and A. K. Nagar, "YOLO-based segmented dataset for drone vs. bird detection for deep and machine learning algorithms," Data Brief, vol. 50, Art. 109355, 2023, doi: 10.1016/j.dib.2023.109355.
- [2] V. Soni, D. Shah, J. Joshi, S. Gite, B. Pradhan, and A. Alamri, "Introducing AOD 4: A dataset for air borne object detection," Data Brief, vol. 56, Art. 110801, 2024, doi: 10.1016/j.dib.2024.110801.
- [3] V. K. Puduru, P. Bethi, S. Koorapati, and L. R. Cenkeramaddi, "Lightweight deep learning model for airborne object classification," in Proc. IEEE 14th Int. Conf. Commun. Syst. Netw. Technol. (CSNT), 2025, pp. 230-234, doi: 10.1109/CSNT64827.2025.10968603.
- [4] A. Pandat, P. Rajasekhar, G. Vinod, and R. Shukla, "Strategies for improved out-of-distribution detection in drone vs. bird classification," Procedia Comput. Sci., vol. 259, pp. 398-407, 2025, doi: 10.1016/j.procs.2025.03.341.
- [5] N. S. H. Al-Zadjali, S. Balasubramanian, C. Savarimuthu, and E. O. Rances, "Bio-inspired motion detection models for improved UAV and bird differentiation: a novel deep learning framework," Sci. Rep., vol. 15, Art. 15521, 2025, doi: 10.1038/s41598-025-99951-4.
- [6] A. Coluccia et al., "Drone vs. bird detection: Deep learning algorithms and results from a grand challenge," Sensors, vol. 21, no. 8, Art. 2824, 2021, doi: 10.3390/s21082824.